

Case Técnico – MR Health

Tarefa teste

Candidato: Felipe Moreira Szczpanski

1. Objetivo

O objetivo deste trabalho foi desenvolver uma solução capaz de:

- consolidar automaticamente os dados históricos de vendas;
- avaliar a qualidade das informações disponíveis;
- identificar padrões de comportamento da demanda;
- construir um modelo preditivo para previsão das quantidades vendidas;
- gerar recomendações que possam apoiar o processo de gestão de estoques.

2. Entendimento dos Dados

Foram disponibilizados três conjuntos de dados.

PEDIDO

Contém as informações gerais de cada pedido realizado.

Campos disponíveis:

- ID do pedido
- Data
- Valor total

ITEM_PEDIDO

Representa os itens pertencentes a cada pedido.

Campos disponíveis:

- ID do pedido
- Produto
- Quantidade

ITENS

Tabela contendo o cadastro dos produtos.

Campos disponíveis:

- Produto
- Preço unitário

3. Análise Exploratória

A etapa exploratória teve como objetivo compreender o comportamento das vendas e identificar padrões relevantes para o desenvolvimento do modelo.

3.1 Receita por Produto




Figura 1 - Receita por produto

3.2 Curva ABC

Classe	Produtos
A	Item D, Item C
B	Item B
C	Item A

3.3 Comportamento Temporal

Foi construída uma série temporal da quantidade total vendida por dia.

Apesar da elevada variabilidade diária, observa-se uma tendência consistente de aumento da demanda durante os finais de semana. A média móvel de sete dias contribui para reduzir oscilações de curto prazo e evidencia esse comportamento.




Figura 2 - Demanda diária

3.4 Sazonalidade Semanal

A análise por dia da semana mostrou um padrão bastante consistente.

Dia	Média de vendas
Segunda	5,0
Terça	7,4
Quarta	6,4
Quinta	6,2
Sexta	13,2
Sábado	14,4
Domingo	15,2

Sexta-feira e finais de semana apresentam mais vendas.




Figura 3 - Demanda média




Figura 4 - Heatmap Demanda média

3.5 Distribuição das Quantidades




Figura 5 - Boxplot distribuição da demanda por produto

4. Engenharia de Variáveis

Como o objetivo consiste em prever demanda diária, foram criadas variáveis capazes de representar o comportamento temporal das vendas.

Entre elas destacam-se:

- dia da semana;
- mês;
- semana do ano;
- indicador de final de semana;
- índice temporal;
- preço unitário;
- Lag 1;
- Lag 7;
- Lag 14;
- média móvel de 7 dias;
- média móvel de 14 dias;
- desvio móvel;
- mínimo e máximo observados na última semana.

As variáveis defasadas foram calculadas utilizando exclusivamente informações anteriores à data prevista, evitando vazamento de informação entre treinamento e teste.

5. Desenvolvimento do Modelo

Como a variável resposta corresponde à quantidade vendida, o problema foi tratado como regressão.

Foram avaliados diferentes algoritmos:

- Regressão Linear;
- Regressão de Poisson;
- Random Forest;
- Gradient Boosting;
- XGBoost.

Além dos modelos supervisionados, foram implementados três modelos de referência:

- média histórica por produto;
- média por produto e dia da semana;
- previsão baseada na demanda observada sete dias antes.

O desempenho foi avaliado por meio das métricas MAE, RMSE, MAPE e R^2 .

6. Avaliação dos Resultados

Durante a validação temporal, o Gradient Boosting apresentou o melhor desempenho médio, obtendo MAE de aproximadamente 2,19 unidades. Na etapa de holdout, entretanto, observou-se desempenho muito próximo entre o modelo treinado e o baseline baseado na média histórica por produto. Essa diferença reduzida indica que, considerando o histórico disponível (aproximadamente três meses), modelos mais sofisticados ainda não apresentam vantagem consistente em relação a abordagens simples.

Esse resultado é esperado em bases pequenas e com elevada variabilidade diária.

MODELO	MAE_MEDIO	RMSE_MEDIO	MAPE_MEDIO	R2_MEDIO
GradientBoosting	2.184661056622476	2.718662448830186	58.853918213855174	0.0006514323856687451
RandomForest	2.2379072900942636	2.701812992266928	59.76290165045152	0.028371233037544297
XGBoost	2.275300050243026	2.734726600641389	60.14939846085057	-0.0013898907655802335
BaselineItemDiaSemana	2.309948979591837	2.7896575145786646	66.2280926030404	-0.036946274554782534
BaselineMediaItem	2.377207130404061	2.788720380674865	52.68641512240172	-0.03215447835298324
Poisson	2.498496359047914	2.908419165099456	66.20861747722473	-0.13491132782064333
RegressaoLinear	2.5735251935465087	3.01670778859272	67.89126181898908	-0.2151794452285066
BaselineSazonalLag7	2.7619047619047623	3.632800655438943	99.28231774723002	-0.7504579180490634




Figura 6 – Holdout: realizado × previsto.




Figura 7 – Resíduos do modelo.

A análise de importância por permutação mostrou que as variáveis mais relevantes foram:

- dia da semana;
- indicador de final de semana;
- média móvel de sete dias;
- lag de sete dias.

Esse resultado confirma as conclusões obtidas durante a análise exploratória, demonstrando coerência entre o comportamento observado nos dados e o aprendizado do modelo.

7. Conclusão

Foi desenvolvida uma solução capaz de consolidar automaticamente os dados históricos, identificar padrões relevantes de comportamento das vendas, construir um modelo preditivo de demanda e gerar recomendações aplicáveis ao processo de gestão de estoques. A análise demonstrou forte sazonalidade semanal, concentração da receita em poucos produtos e potencial para utilização de modelos preditivos como apoio à tomada de decisão.

Embora o Gradient Boosting tenha apresentado o melhor desempenho médio durante a validação temporal, o histórico reduzido disponível ainda favorece abordagens simples em parte das avaliações.